



Интернет на нещата в интелигентните транспортни системи

Изготвил: Денис Табутов



Раздел I


Как IoT се използва в ITS

Какво са ITS и IoT?

Интелигентните транспортни системи използват данни, комуникация и автоматизация за по-добро управление на трафика.

IoT добавя мрежа от устройства, сензори, камери и свързани системи, които събират и обменят данни в реално време.

Комбинацията позволява не само наблюдение, а и по-интелигентни решения за маршрутизиране и управление.



Защо IoT е важен за градския транспорт?

Преминава се от реактивно към проактивно управление на трафика.
Данните идват с голям обем, висока скорост и разнообразни формати.
Това отваря възможност за анализ, прогноза и оптимизация на транспортните потоци.



Архитектура на данните: Edge, Fog и Cloud

Edge: част от обработката се извършва близо до източника на данни.

Fog: междинни възли обединяват и подготвят данните.

Cloud: съхранение, анализ, модели и визуализация на големи обеми транспортни данни.

Cloud


Thousands of Data Centers

Fog

Millions of Nodes

Edge

Billions of Devices



Комуникация и източници на данни

Комуникация: V2V, V2I, V2X.
Технологии: 5G, MQTT, LoRaWAN, API услуги за трафик.
Източници: камери, GPS, пътна инфраструктура, навигационни платформи.




Проблемът в градската мобилност

Задръствания и загуба на време.

По-високи емисии и по-ниска ефективност
на транспорта.

Необходимост от по-интелигентен избор на
маршрут според различни цели.





Раздел II

Архитектура и реализация на Urban Route Optimizer

Цел на проекта

Да се изгради система за интелигентно маршрутизиране в градска среда.


Да се комбинират геопространствени данни, live traffic информация и ML компоненти.

Да се сравнят най-бърз, най-кратък и по-екологичен маршрут.



Urban Route Optimiser: общ преглед

Проектът е реализиран, като Streamlit приложение. Има локален routing engine върху пътна мрежа на София и optional live backend чрез TomTom API. Системата визуализира маршрути, ETA, емисии и допълнителни ML оценки.



Подготовка за данните за София


Използва се пътна информация от OpenStreetMap.
Скриптът `generate_route_network.py` преобразува необработения extract в routable CSV мрежа.
За всеки сегмент се изчисляват дължина, скорост, congestion profile, eco factor и други routing характеристики.



Open Street Map

Алгоритъм и маршрутизиране

Използван е модифициран алгоритъм на Дейкстра.
Системата може да оптимизира по различни критерии: време, дължина, екологичен разход.
Routing логиката е реализирана в route_engine.py.



Scenario view

Balanced

Fastest

Lowest emissions

Green corridor

Displayed route

36.1 min

Estimated CO2

5.52 kg

Avg green score

0.68

Delivery plan

Direct

ML route forecast

ML ETA

34.9 min

↓ -1.2 min

Predicted traffic

High

High traffic share

84%

Corridor confidence

0.29

These predictions come from the trained tabular models in ml_demo. They are also feeding the local optimizer in Hybrid ML-aware mode.

Scenario view

Balanced

Fastest

Lowest emissions

Green corridor

Displayed route

40.5 min

Estimated CO2

3.76 kg

Avg green score

0.54

Delivery plan

Direct

ML route forecast

ML ETA

40.1 min

↓ -0.3 min

Predicted traffic

High

High traffic share

60%

Corridor confidence

0.23

These predictions come from the trained tabular models in ml_demo. They are also feeding the local optimizer in Hybrid ML-aware mode.


Live traffic интеграция и ограничения

При наличен API ключ приложението използва live traffic данни от TomTom. Live интеграцията е реализирана в `live_routing.py`.
Важно ограничение: локалният режим остава моделиран и не използва директни feeds от реални светофари контролери.



ML в самото приложение

В проекта има и Sofia-specific ML компоненти за ETA, congestion и green-corridor оценка. Те подпомагат локалния routing flow и са полезни за техническа демонстрация.




Отделното ML demo

Добавен е самостоятелен tabular ML demo проект.

Той е върху реален външен dataset, а не върху вътрешно генерирани таргети.

Това включва: dataset, trained model, result.



Dataset за ML демото

Използван е Metro Interstate Traffic Volume от UCI Machine Learning Repository. Dataset-ът съдържа 48,204 почасови наблюдения за трафик, време и прачнични дни. Локално е включен в проекта и е описан в ml_demo/README.md

Metro_Interstate_Traffic_Volume								
holiday	temp	rain_1h	snow_1h	clouds_all	weather_main	weather_description	date_time	traffic_volume
None	288.28	0.0	0.0	40	Clouds	scattered clouds	2012-10-02 09:00:00	5545
None	289.36	0.0	0.0	75	Clouds	broken clouds	2012-10-02 10:00:00	4516
None	289.58	0.0	0.0	90	Clouds	overcast clouds	2012-10-02 11:00:00	4767
None	290.13	0.0	0.0	90	Clouds	overcast clouds	2012-10-02 12:00:00	5026
None	291.14	0.0	0.0	75	Clouds	broken clouds	2012-10-02 13:00:00	4918
None	291.72	0.0	0.0	1	Clear	sky is clear	2012-10-02 14:00:00	5181
None	293.17	0.0	0.0	1	Clear	sky is clear	2012-10-02 15:00:00	5584
None	293.86	0.0	0.0	1	Clear	sky is clear	2012-10-02 16:00:00	6015
None	294.14	0.0	0.0	20	Clouds	few clouds	2012-10-02 17:00:00	5791
None	293.1	0.0	0.0	20	Clouds	few clouds	2012-10-02 18:00:00	4770
None	290.97	0.0	0.0	20	Clouds	few clouds	2012-10-02 19:00:00	3539
None	289.38	0.0	0.0	1	Clear	sky is clear	2012-10-02 20:00:00	2784
None	288.61	0.0	0.0	1	Clear	sky is clear	2012-10-02 21:00:00	2361
None	287.16	0.0	0.0	1	Clear	sky is clear	2012-10-02 22:00:00	1529
None	285.45	0.0	0.0	1	Clear	sky is clear	2012-10-02 23:00:00	963
None	284.63	0.0	0.0	1	Clear	sky is clear	2012-10-03 00:00:00	506
None	283.47	0.0	0.0	1	Clear	sky is clear	2012-10-03 01:00:00	321
None	281.18	0.0	0.0	1	Clear	sky is clear	2012-10-03 02:00:00	273
None	281.09	0.0	0.0	1	Clear	sky is clear	2012-10-03 03:00:00	367
None	279.53	0.0	0.0	1	Clear	sky is clear	2012-10-03 04:00:00	814
None	278.62	0.0	0.0	1	Clear	sky is clear	2012-10-03 05:00:00	2718
None	278.23	0.0	0.0	1	Clear	sky is clear	2012-10-03 06:00:00	5673
None	278.12	0.0	0.0	1	Clear	sky is clear	2012-10-03 08:00:00	6511
None	282.48	0.0	0.0	1	Clear	sky is clear	2012-10-03 09:00:00	5471
None	291.97	0.0	0.0	1	Clear	skv is clear	2012-10-03 12:00:00	5097

Обучени модели

Regression задача: Ridge модел за предсказване на traffic_volume.

Classification задача: LogisticRegression за low/medium/high traffic bands.

Използван е chronological split: 70/15/15, за да се избегне темпорал leakage.

Има и baseline сравнение с DummyRegressor и DummyClassifier.



Резултати


Regression: $R^2 = 0.7162$, RMSE = 1056.86, MAE = 825.19.

Classification: Accuracy = 0.7960, F1 macro = 0.7951.

Baseline резултатите са значително по-слаби, което показва, че моделите научават реални зависимости.

Подробните метрики са записани в `uci_traffic_demo_results.json`.

```
"result": {  
  "ridge_test_r2": 0.7161603683944724,  
  "ridge_test_rmse": 1056.8552700950754,  
  "logreg_test_accuracy": 0.7960171483888812,  
  "logreg_test_f1_macro": 0.7951460298346636  
}
```



Live Demo




Раздел III

Демонстрация на приложението

Технологичен стек

Python 3.13, Streamlit, Pandas, NumPy, scikit-learn.

Модулите, dataset-ът, README и резултатите са прикачени в: <https://github.com/denjiyy/IoTinITS>



Заключение

IoT е ключов елемент в развитието на интелигентните транспортни системи. Urban Route Optimiser показва как routing, live traffic и ML могат да се комбинират в един проект.





Thank you!